

SERIJALIZACIJA PODATAKA



ŠTA JE POTREBNO ZA KOMUNIKACIJU?

2

INTERFEJS

- Deljena granica preko koje dve ili više odvojenih komponenti sistema razmenjuju informacije [1]

PROTOKOL

- HTTP
- MQTT
- SMTP
- ...

FORMAT PORUKE

- Kroz striktno definisanu šemu
- Kroz neformalni dogovor





FORMATI ZA SERIJALIZACIJU PORUKA

3

POSTOJE BAR DVE REPREZENTACIJE PODATAKA

- U memoriji se čuvaju u strukturama, listama, heš tabelama, stablima, objektima, ...
- Za čuvanje u fajl na disku ili slanje preko mreže mora se izvršiti konverzija u nekakav niz bajtova

SERIJALIZACIJA (MARSHALLING)

- Konverzija iz reprezentacije podatka u memoriji u bajt sekvencu

DESERIJALIZACIJA (UNMARSHALLING)

- Konverzija iz bajt sekvence u reprezentaciju podatka u memoriji





FORMATI SPECIFIČNI ZA JEZIK

4

PROGRAMSKI JEZICI IMAJU UGRAĐENU PODRŠKU ZA KONVERZIJU

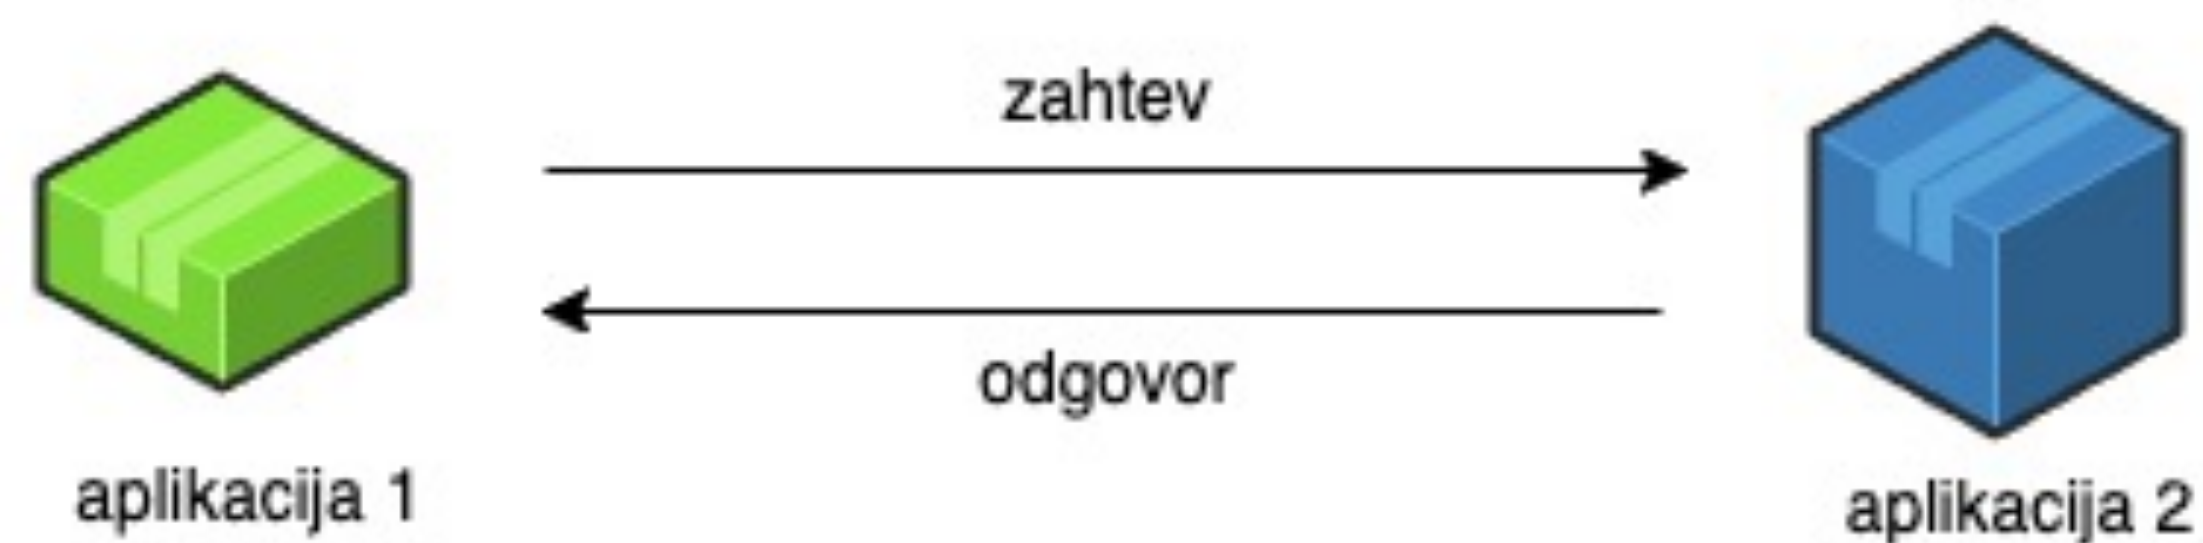
- Java – Serializable
- Python – pickle
- ...

PREDNOST

- Sa minimalnom količinom koda se može izvršiti konverzija podatka

MANE

- Čvrsta veza sa programskim jezikom
- Za potrebe deserijalizacije, aplikacija 2 treba da ima mogućnost da konstruiše iste klase kao aplikacija 1 (mimic)
- Loše performanse





STANDARDIZOVANI TEKSTUALNI FORMATI

5

PREDNOST

- Mogu ih kreirati i čitati različiti programski jezici
 - JSON
 - XML
 - CSV

MANE

- Problem reprezentacije brojeva
- Nedostatak obavezne validacije šeme
- Nedostatak podrške za binarne stringove

JSON:

```
{
  "id": "17",
  "name": "Pera",
  "lastname": "Perić",
}
```

XML:

```
<student>
  <id>17</id>
  <name>Pera</name>
  <lastname>Perić</lastname>
</student>
```


CSV:

```
17,Pera,Perić
```

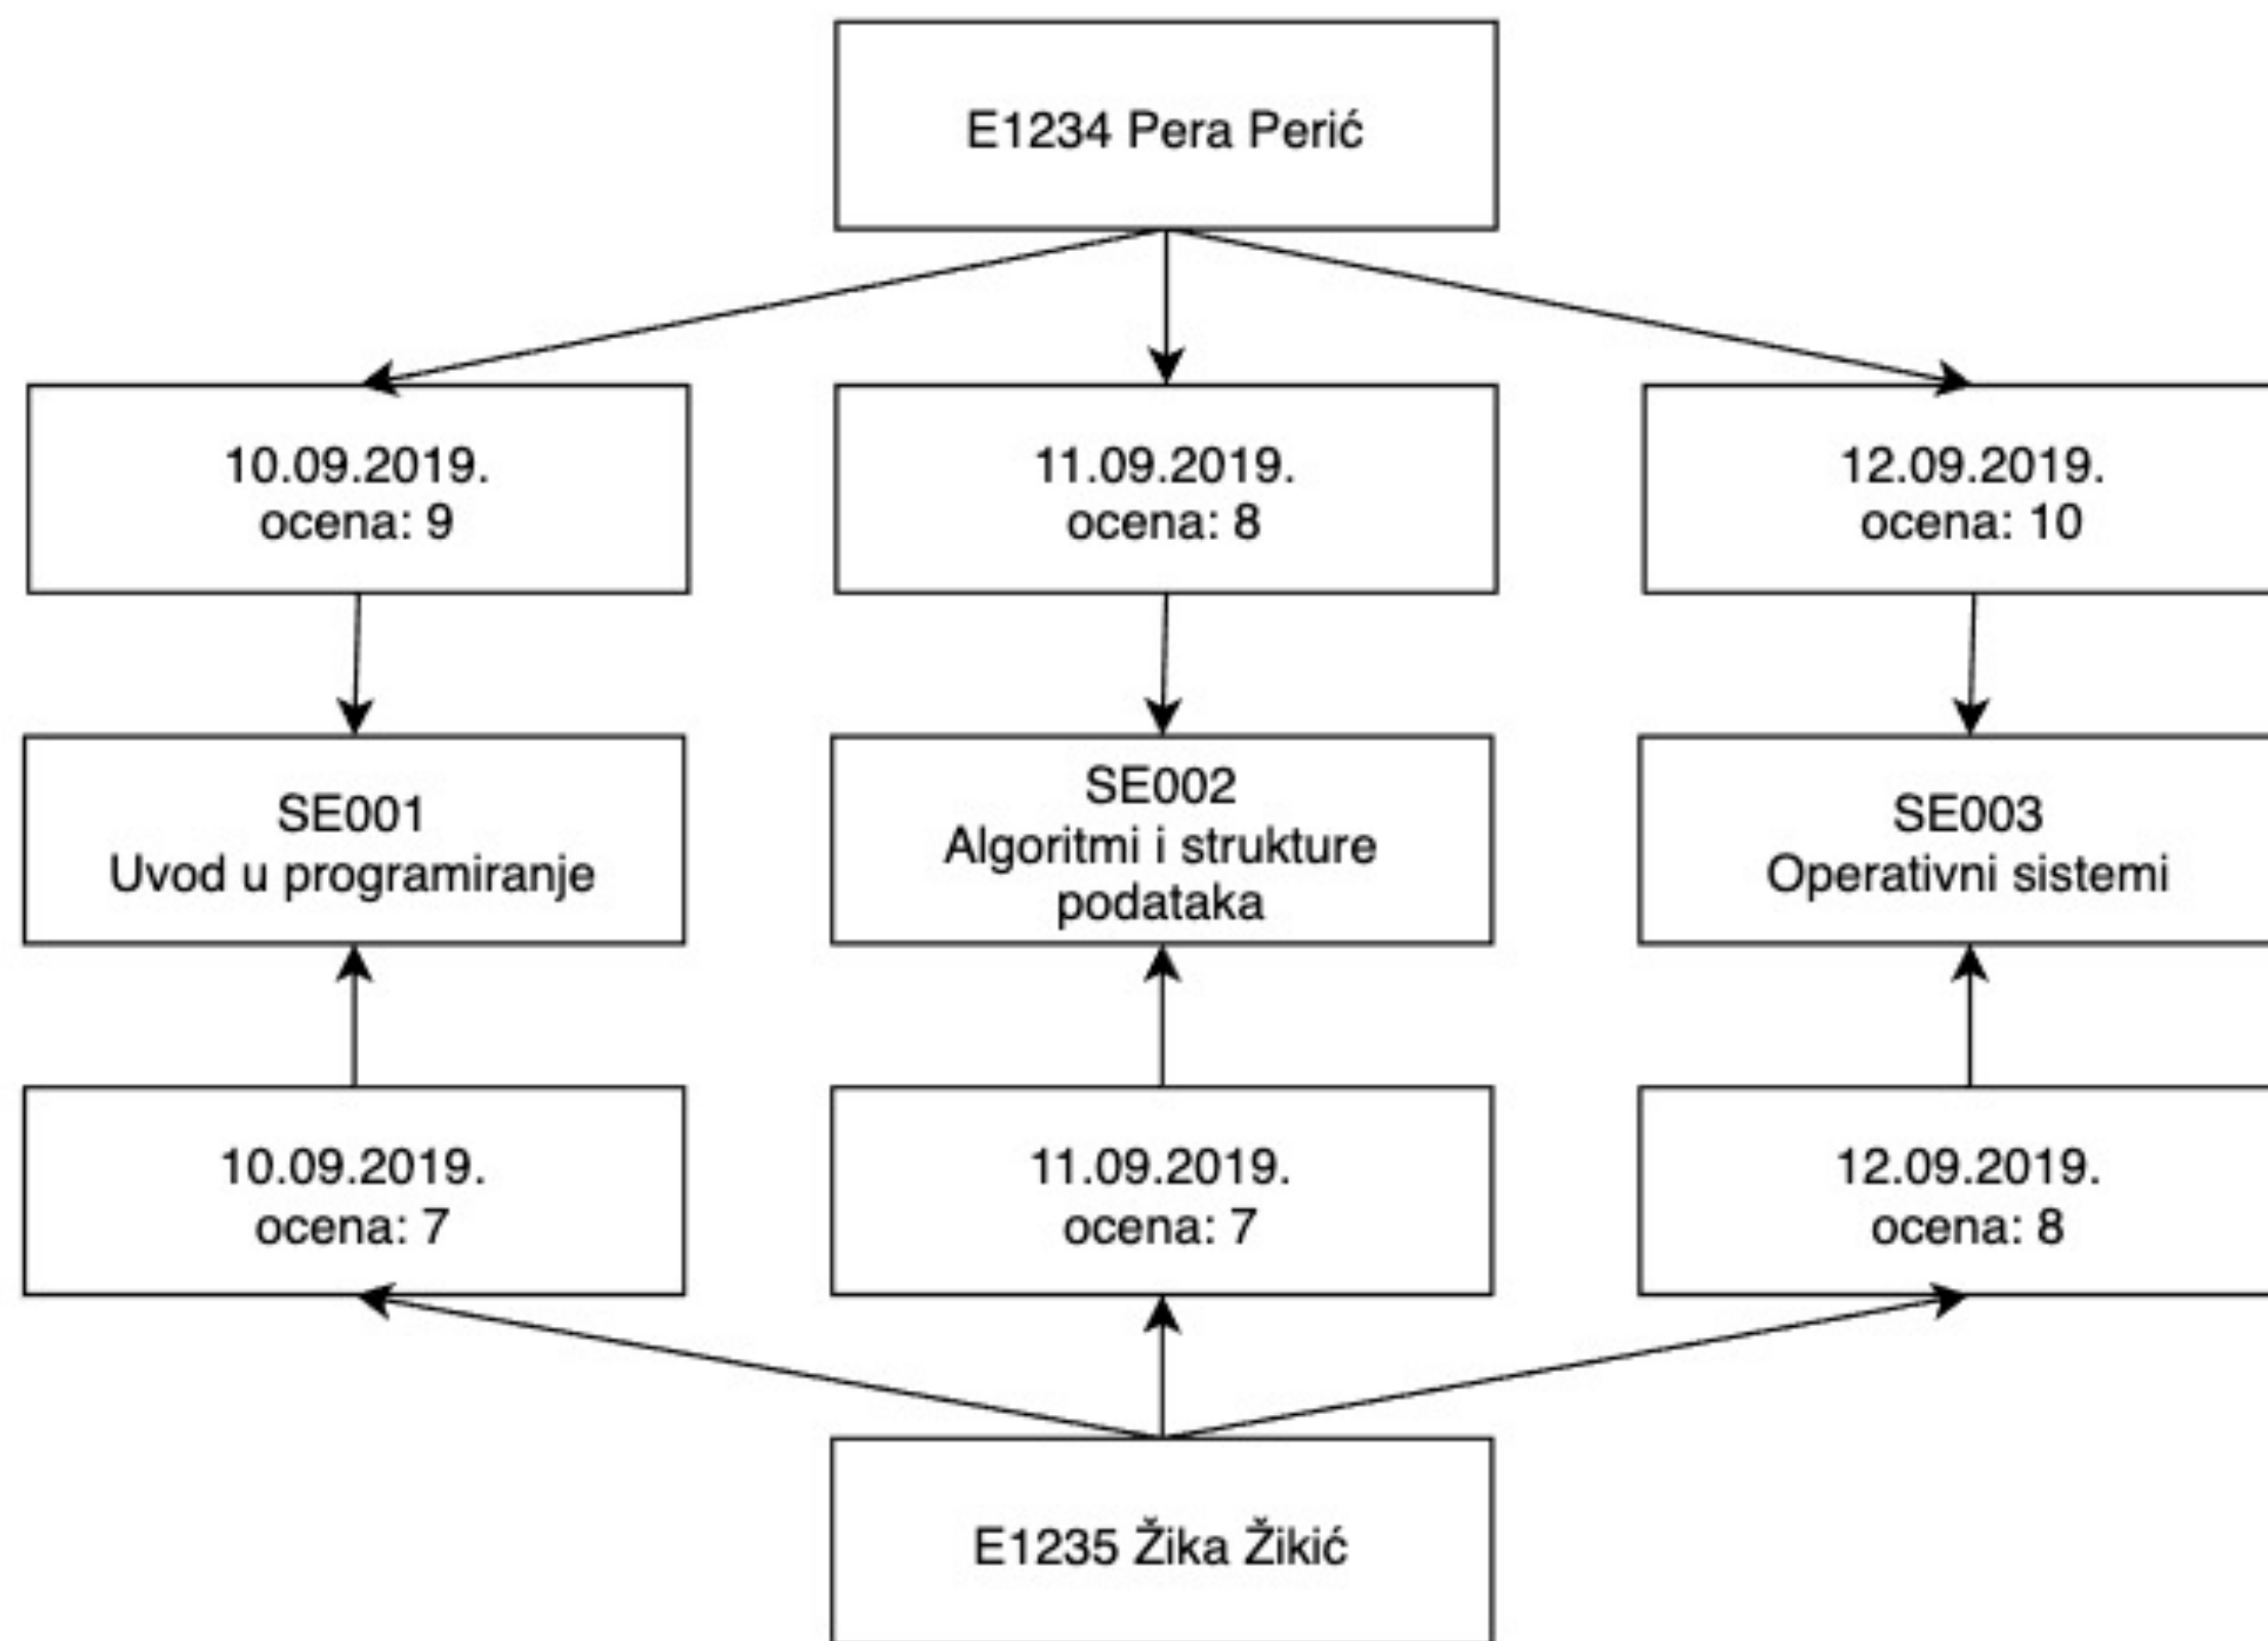


PROBLEM


6



PROBLEM



PROBLEM





BINARNI FORMATI

9

POSTAJU POPULARNI KAO ALTERNATIVA TEKSTUALNIM

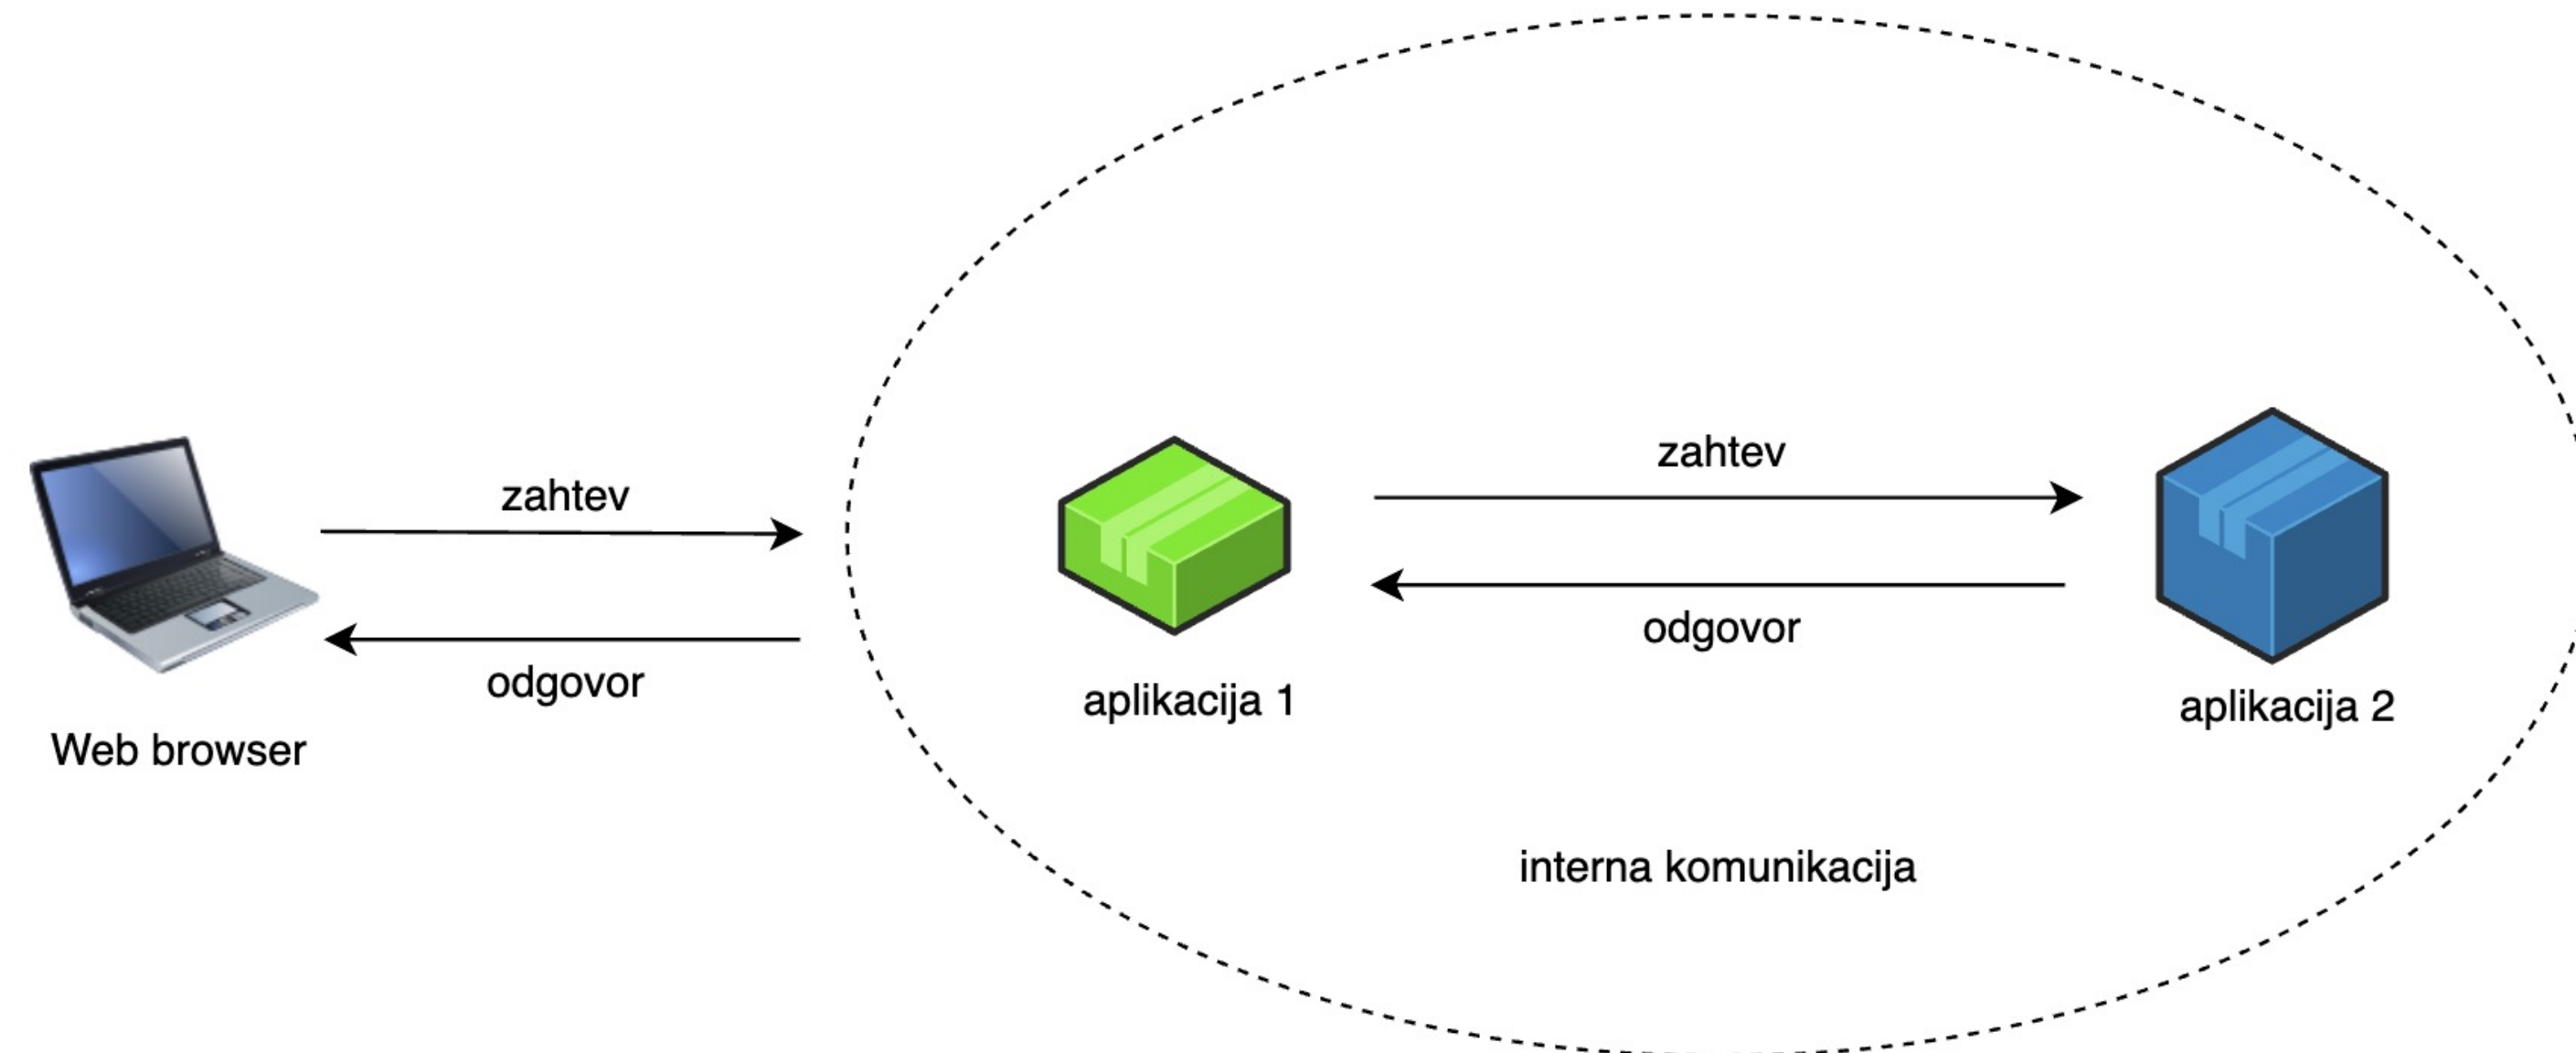
- Protocol Buffers (protobuf)
- Apache Thrift
- Apache Avro
- FlatBuffers

PREDNOSTI

- Manje prostora zauzimaju poruke
- Obavezna validacija u odnosu na šemu
- Generisanje koda na osnovu šeme za lakše korišćenje
- Mogućnost verzionisanja poruka

MANE

- Mora se definisati šema, tj. izgled poruke što je podložno greškama
- Generisanje koda zahteva korišćenje generatora, tj. savladavanja nečeg novog





BINARNI FORMATI

10

POSTAJU POPULARNI KAO ALTERNATIVA TEKSTUALNIM

- Protocol Buffers (protobuf)
- Apache Thrift
- Apache Avro
- FlatBuffers

PREDNOSTI

- Manje prostora zauzimaju poruke
- Obavezna validacija u odnosu na šemu
- Generisanje koda na osnovu šeme za lakše korišćenje
- Mogućnost verzionisanja poruka

MANE

- Mora se definisati šema, tj. izgled poruke što je podložno greškama
- Generisanje koda zahteva korišćenje generatora, tj. savladavanja nečeg novog

Protobuf schema:

```
message Student {  
    required int64 id = 1;  
    required string name = 2;  
    required string lastname = 3;  
}
```

Thrift schema:

```
struct Student {  
    1: required i64 id,  
    2: required string name,  
    3: required string lastname  
}
```

Avro IDL schema:

```
record Student {  
    int id;  
    string name;  
    string lastname;  
}
```



BINARNI FORMATI

11

1. Kreiraj šemu

.PROTO

```
message Student {  
    required int64 id = 1;  
    required string name = 2;  
    required string lastname = 3;  
}
```

primer: serijalizacijaProto

2. Generiši fajlove za željeni jezik
i ne menjaj ih


GENERATE


```
protoc -I=$SRC_DIR --java_out=$DST_DIR  
$SRC_DIR/student.proto
```

```
protoc -I=$SRC_DIR --python_out=$DST_DIR  
$SRC_DIR/student.proto
```

3. Implementiraj klijentsku i serversku
aplikaciju koje će raditi
serijalizaciju/deserijalizaciju



IMPLEMENTATION





TRI NAJČEŠĆA SCENARIJA U KOJIMA SE RAZMENJUJU PODACI

- Serverska aplikacija <-> Baza podataka
- Direktna komunikacija klijent <-> server kroz poziv servisa
- Asinhrona komunikacija razmenom poruka preko reda poruka (message queue)





REFERENCE

- ◆ **PRIMERI PO UZORU NA** <https://github.com/mbranko/isa19/tree/master/02-serialization>
- ◆ **JAVA OBJECT SERIALIZATION SPECIFICATION**
<https://docs.oracle.com/javase/7/docs/platform/serialization/spec/serialTOC.html>
- ◆ **PYTHON PICKLE** <https://docs.python.org/3/library/pickle.html>
- ◆ **GOOGLE PROTOCOL BUFFERS** <https://developers.google.com/protocol-buffers>
- ◆ **APACHE THRIFT PROTOCOL** <https://thrift.apache.org/>
- ◆ **APACHE AVRO** <https://avro.apache.org/docs/current/>
- ◆ **DESIGNING DATA-INTENSIVE APPLICATIONS** by MARTIN KLEPPMANN <https://bit.ly/30gFSz3>
- ◆ **TWITTER API IDs** <https://developer.twitter.com/en/docs/twitter-ids>
- ◆ **MICROSOFT – MESSAGE ENCODING CONSIDERATIONS**
<https://docs.microsoft.com/en-us/azure/architecture/best-practices/message-encode>
- ◆ **WOLNIKOVSKI ET AL. ZERIALIZER: TOWARDS ZERO-COPY SERIALIZATION**
<https://dl.acm.org/doi/pdf/10.1145/3458336.3465283>
- ◆ **SUMARAY A., KAMI MAKKI S. A COMPARISON OF DATA SERIALIZATION FORMATS FOR OPTIMAL EFFICIENCY ON A MOBILE PLATFORM** <https://dl.acm.org/doi/pdf/10.1145/2184751.2184810>
- ◆ **POPIC ET AL. PERFORMANCE EVALUATION OF USING PROTOCOL BUFFERS IN THE INTERNET OF THINGS COMMUNICATION** <https://bit.ly/3GsvbxA>

**KOJA SU VAŠA
PITANJA?**